ПРОГНОЗИРОВАНИЕ РИСКА ИНТРАКРАНИАЛЬНОЙ ПРОГРЕССИИ МЕТАСТАЗОВ В ГОЛОВНОМ МОЗГЕ ПОСЛЕ РАДИОХИРУРГИИ НА ГАММА-НОЖЕ: РАЗРАБОТКА ПРОГНОСТИЧЕСКОЙ МОДЕЛИ МОДЕЛИ НА ОСНОВЕ МАШИННОГО ОБУЧЕНИЯ И ВЫЯВЛЕНИЕ КЛЮЧЕВЫХ ФАКТОРОВ

© 2025 г. С. В. Васюнина, А. П. Зубков
А. В. Борголов, Е. В. Глушенкова

Центральный университет, 123056, г. Москва, ул. Гашека, д. 7, стр. 1
s.vasyunina@edu.centraluniversity.ru

Аннотация

В исследовании проанализированы обезличенные клинические данные 916 пациентов с метастазами в головной мозг (МГМ), проходивших лечение радиохирургией на аппарате «Гамма-нож» в период с июня 2005 по январь 2017 г. Выборка включала МГМ из различных первичных очагов: рак молочной железы (25%), немелкоклеточный рак лёгкого (32%), меланома (18%), рак почки (15%) и колоректальный рак (10%). Целевая переменная — бинарный признак интракраниальной прогрессии (ИП), включающий локальные рецидивы и дистантные метастазы.

С использованием RandomizedSearchCV и CatBoostClassifier (depth=7, learning_rate=0.027, iterations=354) достигнуты balanced_accuracy 0.754 (OOF) и 0.771 (тест 80/20, threshold=0.64).

SHAP-анализ выявил ключевые факторы риска ИП: число радиохирургических процедур на ГН (53.0% вклада, mean|SHAP|=1.22), число очагов в ГМ (10.4%, 0.24), возраст (5.8%, 0.13), время реагирования (5.3%, 0.12), индекс Карновского (5.3%, 0.12).

Разработанная модель обеспечивает достаточно точную стратификацию риска ИП после РХ МГМ и может быть использована для персонализации постлучевой терапии в клинической практике с доработками.

Ключевые слова: наука, машинное обучение, прогнозирование, метастазы головного мозга, «Гамма-нож», интракраниальная прогрессия, клинические данные, нейроонкология

1 Введение

МГМ представляют собой серьезную глобальную проблему здравоохранения и являются критическим фактором, поскольку медиана выживаемости без лечения не превышает одного месяца, что подчеркивает агрессивный характер заболевания.[1] Развитие МГМ сопровождается появлением неврологической симптоматики, что приводит к стремительному снижению качества жизни и функциональной независимости пациента. Частота метастатического поражения головного мозга существенно варьирует в зависимости от типа первичной опухоли: наиболее часто МГМ развиваются при немелкоклеточном раке легких.[1]

В современной медицине существует несколько подходов к лечению МГМ. Как правило они комбинируются и используются комплексно, в зависимости от состояния пациента ему может потребоваться нейрохирургическое вмешательство, облучение всего головного мозга (ОВГМ), системную лекарственную терапию и стереотаксическую радиотерапию (СРТ). В последние десятилетия роль СРТ значительно возросла из-за ее высокой эффективности и меньшего риска осложнений. РХ с использованием аппарата ГН является одним из наиболее точных и эффективных методов, позволяющим селективно воздействовать на небольшие внутричерепные поражения с минимальным повреждением здоровых тканей. РХ обеспечивает высокие показатели локального контроля МГМ, особенно при радиорезистентных опухолях, таких как меланома и рак почки.[1]

Однако даже самые современные методы лечения воздействуют только на уже выявленные очаги и не предотвращают появление новых, поэтому после успешного проведения РХ на ГН остается актуальной проблема ИП, которая включает появление новых метастазов (дистантные метастазы) или рост/повторное появление опухоли в месте облучения (локальные рецидивы). Развитие ИП приводит к ухудшению неврологических функций, снижению качества жизни и может значительно сократить продолжительность жизни пациента.[2] Таким образом, отсутствие единого стандарта лечения и необходимость выбора тактики в зависимости от множества факторов, включая количество и расположение метастазов, общее состояние пациента и тип первичной опухоли, подчеркивают актуальность разработки новых, персонализированных подходов к прогнозированию исходов лечения.

Традиционные прогностические системы, такие как Рекурсивный парциальный анализ (RPA) и Градационная прогностическая оценка (GPA), представляли собой ранние попытки оценки общей выживаемости (ОВ) пациентов с МГМ. RPA была ограничена анализом только статистически значимых факторов и предоставляла усредненный прогноз для группы пациентов. [2] GPA, хотя и являлась шагом вперед, также базировалась на ограниченном наборе дискретных факторов и не могла учесть весь современный объем клинической информации, что критично в современной медицине. [2]

С развитием технологий возникла необходимость во внедрении новых инструментов анализа, таких как МО, которое позволяет анализировать эти сложные массивы данных и создавать многофакторные прогностические и диагностические модели, преодолевая ограничения стандартной медицинской статистики. Применение искусственного интеллекта (ИИ) в нейроонкологии уже продемонстрировало потенциал для улучшения прогноза и персонализации лечения. [3]

В контексте лечения МГМ с использованием ГН были проведены исследования с применением МО. В частности, в работе алгоритмы МО (регрессионная модель, обученная с использованием градиентного бустинга) были использованы для прогнозирования ОВ 916 пациентов с МГМ, прошедших РХ на ГН. В результате этой работы медианная погрешность прогнозирования времени от начала болезни до неблагоприятного исхода составила 1,4 месяца. Было обнаружено, что наиболее значимым фактором для предсказания ОВ является объем очага с наибольшим объемом, подвергнутого первой радиохирургии, наряду с суммарным объемом очагов, отсутствием ИП и индексом Карновского (ИК).[2]

Однако, несмотря на успехи в прогнозировании ОВ, предшествующие работы не фокусировались на непосредственном прогнозировании бинарного события - риска развития интракраниальной прогрессии (ИП) - как ключевого фактора, определяющего тактику последующего лечения и качество жизни пациента после РХ.

2 Постановка задачи по прогнозированию интракраниальной прогрессии МГМ на аппарате ГН

В данном исследовании ставится цель выяснить, какие факторы влияют на риск развития интракраниальной прогрессии у пациентов с МГМ после проведения РХ на ГН.

Для достижение данной цели необходимо применять методы МО и решить две основные задачи:

1. Создание прогностической модели. Построить модель МО, которая сможет с высокой точностью предсказывать наличие или отсутствие интракраниальной прогрессии у пациентов после РХ.

2. Анализ влияющих факторов. На основе модели выяснить, какие факторы сильнее всего влияют на развитие ИП.

3 Описание данных и подготовка

3.1 Источник и характеристики выборки

Обезличенные клинические данные получены из базы Единого регистра пациентов, леченных радиохирургией на аппарате «Гамма-нож» за период июнь 2005 – январь 2017 гг. В анализ включены 916 пациентов с метастазами в головной мозг (МГМ) различных гистотипов первичных опухолей.

Демография выборки:

- Возраст: диапазон 24–84
- Пол: мужчины 41% (n=361), женщины 59% (n=511)
- Первичные локализации: РМЖ (31.2%, n=212), НМРЛ (26%, n=177), меланома (21.2%, n=144), РП (14.4%, n=98), КРР (7.2%, n=49)

3.2 Признаки и обработка пропусков

Для моделирования использовались клинико-радиологические и леченческие признаки, представленные в таблице 1. Каждый пациент описывался одной строкой, столбцы соответствовали отдельным переменным (демографические

характеристики, первичный онкологический диагноз, предшествующее лечение, параметры радиохирургии и последующее наблюдение). Признаки включали как числовые, так и бинарные и категориальные.

Таблица 1: Основные признаки и правила обработки пропусков

Признак	**Тип**	**Пропуски**	**Стратегия обработки**
Пол	бинарный (М/Ж)	нет	без изменений
Возраст на момент первой РХ	числовой	единичные	замена на медиану по выборке
Первичный онкологический диагноз (РМЖ, НМРЛ, меланома, РП, КРР)	категориальный	нет	one-hot кодирование при подготовке к моделированию
Наличие активирующих мутаций	бинарный	возможны	замена на модальное значение
Экстракраниальные метастазы на момент РХ	бинарный	возможны	замена на модальное значение
Облучение всего головного мозга (ОВГМ)	бинарный	возможны	замена на модальное значение
Нейрохирургическая операция на ГМ	бинарный	возможны	замена на модальное значение
Лекарственное лечение (без лечения / химиотерапия / таргетная терапия)	категориальный	возможны	замена на модальное значение, последующее one-hot кодирование
Число РХ-процедур на ГН	числовой (целый)	нет	без изменений
Число очагов в ГМ при первой РХ	числовой (целый)	нет	без изменений
Суммарный объём очагов, см^3	числовой	единичные	замена на медиану
Объём максимального очага, см^3	числовой	единичные	замена на медиану
Индекс Карновского	порядковый (0–100)	возможны	замена на модальное значение по выборке

3.3 Формирование целевой переменной

Целевая переменная “Интракраниальная прогрессия” (ИП) сформирована как бинарный признак по формуле:

$$\text{ИП} = \text{локальный рецидив} \vee \text{новые очаги} \vee \text{рост в зоне облучения} \quad (1)$$

4 Предобработка данных

На этапе подготовки данных была выполнена комплексная предварительная обработка, направленная на повышение качества и корректности входных данных.

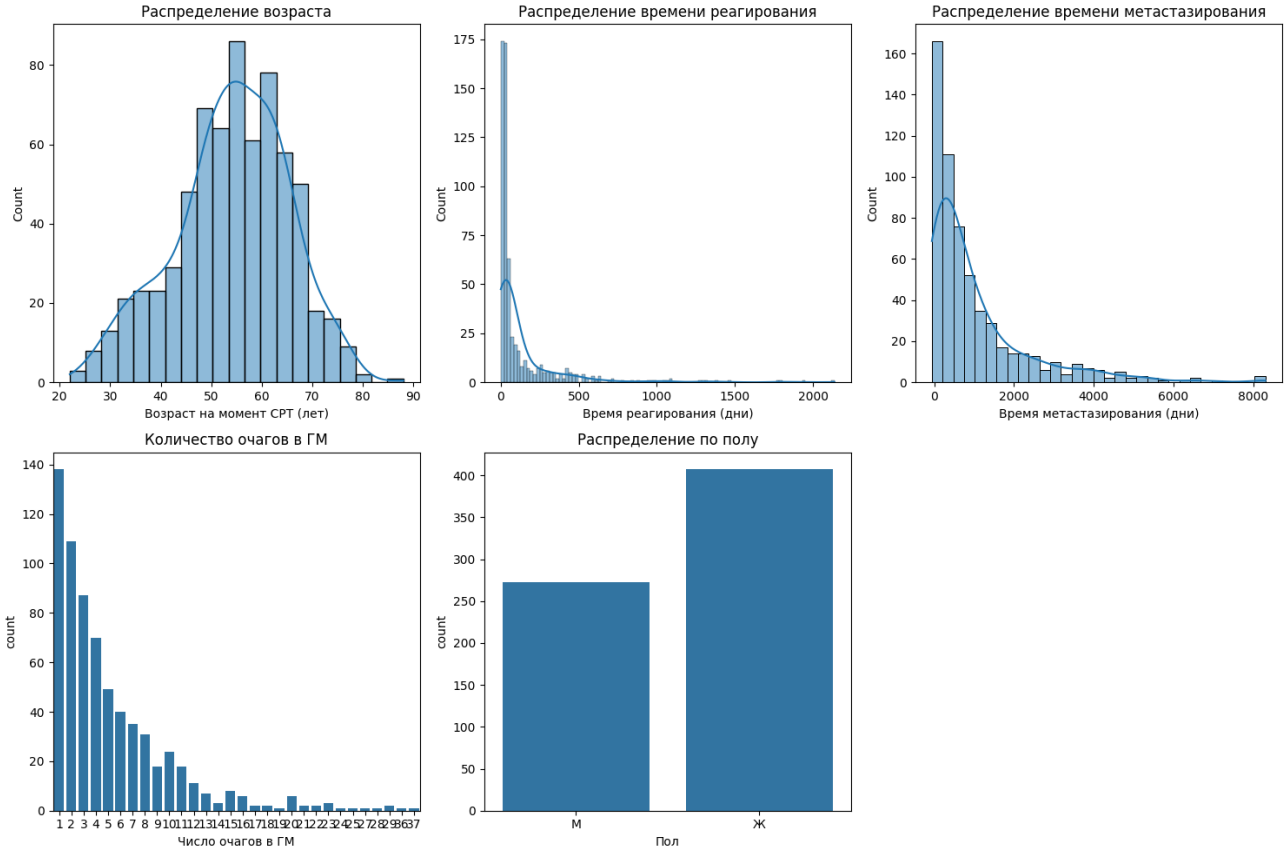

Рис. 1: Разведочный анализ входных данных

Анализ распределения пациентов по полу показал преобладание женщин, это может быть связано с высокой долей первичных опухолей, характерных для женского пола(рак молочной железы), что подтверждается рас-

пределениями первичных локализаций. Наименьший потенциал к метастазированию в головной мозг наблюдается у колоректального рака.

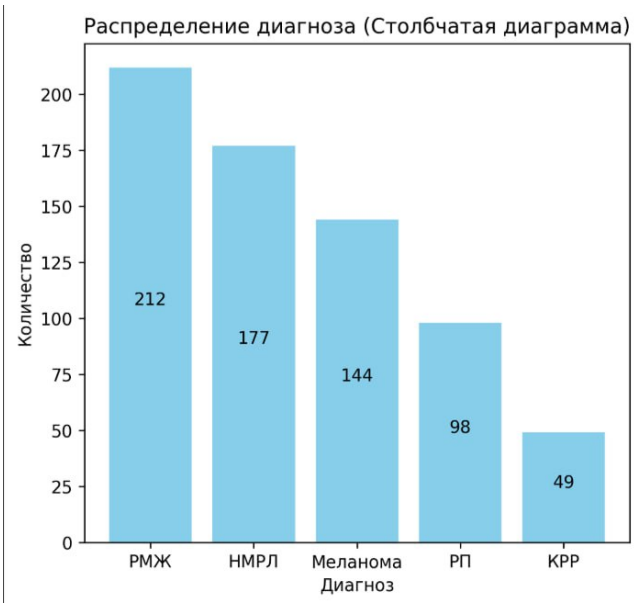

Рис. 2: Распределения диагнозов

Распределение возрастных характеристик (рисунок 1, гистограмма 1) охватывает широкий диапазон от 20 до 90 лет, с наибольшей концентрацией пациентов в интервале 50–70 лет и пиком около 55 лет.

Распределение времени реагирования между развитием метастазов и проведением СРТ имеет экспоненциальный характер (рисунок 1, гистограмма 2), с максимальной частотой в интервале 1–10 дней и резким снижением после 50 дней.

Распределение времени от постановки первичного онкологического диагноза до развития метастазов в головной мозг (рисунок 1, гистограмма 3) характеризуется пиком в первые 200–250 дней, что указывает на агрессивное течение заболевания с ранним метастатическим распространением.

Корреляционный анализ выявил отсутствие сильных взаимосвязей между исследуемыми параметрами, что свидетельствует о статической независимости большинства анализируемых признаков.

Рис. 3: Корреляционный анализ признаков

Для обеспечения сопоставимости клинических и лабораторных показателей, выраженных в различных единицах измерения, был выполнен этап нормализации данных, поскольку многие алгоритмы чувствительны к масштабу входных переменных.

1. Индекс Карновского (шкала оценки функционального состояния онкологических пациентов)

2. Число РХ процедур на головном мозге

3. Число очагов в головном мозге
4. Объем максимального очага
5. Время реагирования на терапию (дни)
6. Время до метастазирования (дни)

Нормализация признаков выполнялась с использованием метода Min–Max scaling, который переводит исходные значения признаков в диапазон [0,1] по формуле:

$$x_{norm} = \frac{x - x_0}{S}$$

где $S = x_{max} - x_{min}$, $x_0 = x_{min}$, x_{min} и x_{max} - минимальное и максимальное значение признаков соответственно.

Для оценки факторов, связанных с прогрессией заболевания (целевой признак «Прогрессия»: 0 — нет прогрессии, 1 — есть прогрессия), были проанализированы числовые и категориальные признаки.

Числовые признаки сравнивались между группами с/без прогрессии с помощью устойчивых мер (медианы, межквартильные размахи, процент перекрытия распределений), а также визуализировались через кривые плотности с указанием медиан обеих групп

Категориальные признаки анализировались с помощью таблиц сопряжённости 2×2 и оценки риска прогрессии, относительного риска (RR) и отношения шансов (OR). Для многозначного диагноза дополнительно был применён X^2-тест и коэффициент связи V Крамера.

Результаты анализа числовых признаков

Признак	μ (без прогр.)	μ (с прогр.)	Различие (%)	Перекрытие (%)
Число очагов	0.16	0.22	37.14	84.63
Объём очагов	0.17	0.16	9.15	93.33
Число РХ процедур	0.00	0.14	3958.63	21.87
Индекс Карновского	0.64	0.67	5.28	89.83
Возраст	0.54	0.52	5.46	94.22
Время метастазирования	0.14	0.15	11.47	91.48
Время реагирования	0.15	0.13	12.27	93.29

Рис. 4: Результат анализа числовых признаков

5 Интерпретация

Число РХ процедур. По таблице(рис. 4) видно, что среднее число процедур у пациентов с прогрессией (0.14) существенно выше, чем у пациентов без прогрессии (0.00), а перекрытие распределений между группами составляет всего 21.87 %.
На визуализации распределения этого признака практически все пациенты, у которых были РХ-процедуры, относятся к группе с прогрессией(рис. 5 а).
Клинически это означает, что необходимость таких процедур сама по себе является индикатором тяжёлого течения.

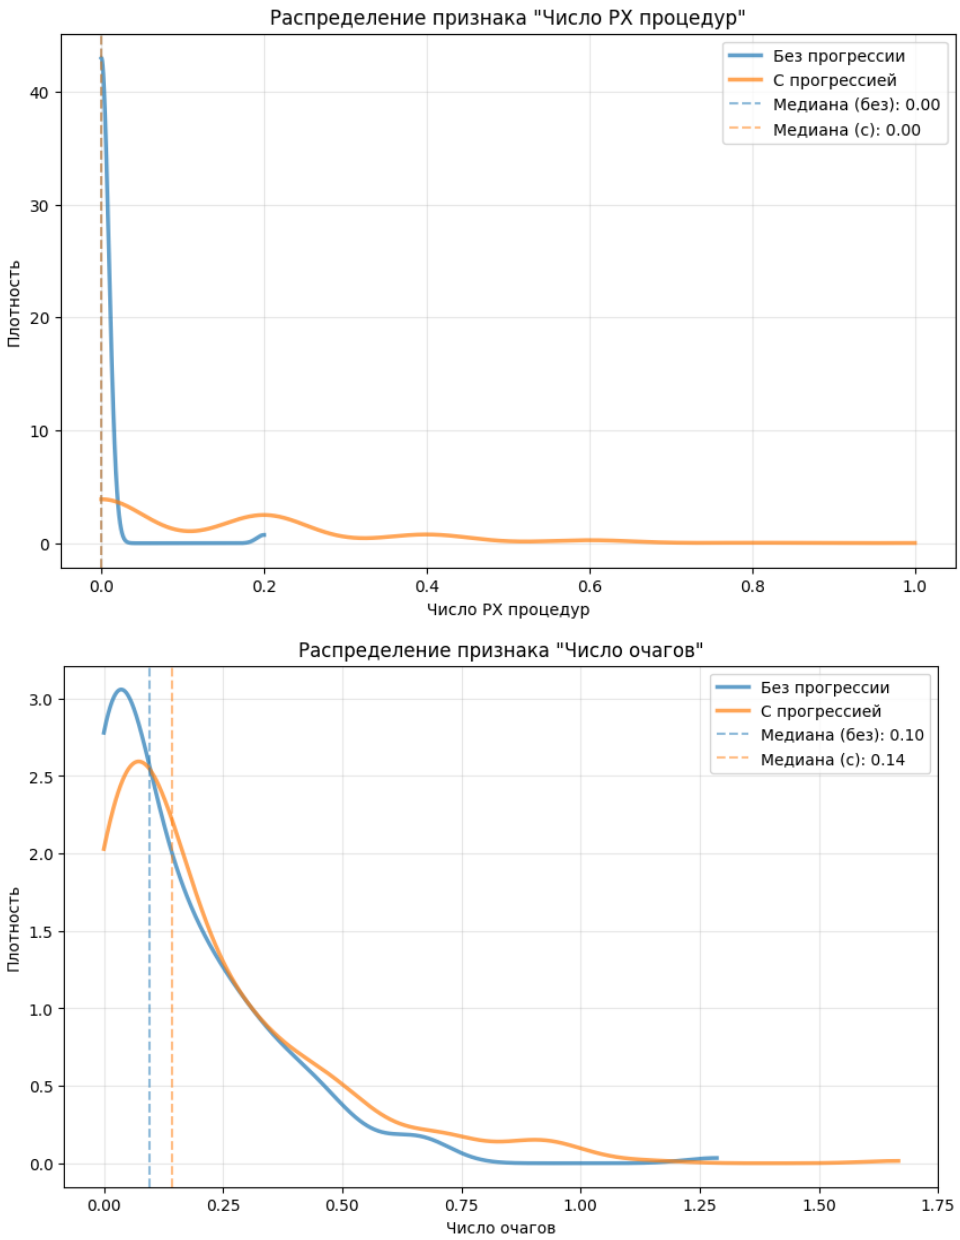

Рис. 5: а и б

Число очагов. Среднее число очагов выше у пациентов с прогрессией (0.22 против 0.16); относительное различие составляет 37 %.
На графике плотности для признака «Число очагов» медиана у пациентов с прогрессией смещена вправо относительно медианы пациентов без прогрессии (рис. 5 б), что согласуется с тем, что более распространённый процесс даёт больший риск ухудшения.

Объём очагов. Средние значения очень близки (0.17 без прогрессии и 0.16 с прогрессией), перекрытие распределений >90%.
На графике видно, что кривые плотности для обеих групп почти совпадают (рис. 6 а).
Следовательно, сам по себе объём поражения не даёт явного прогностического сигнала.

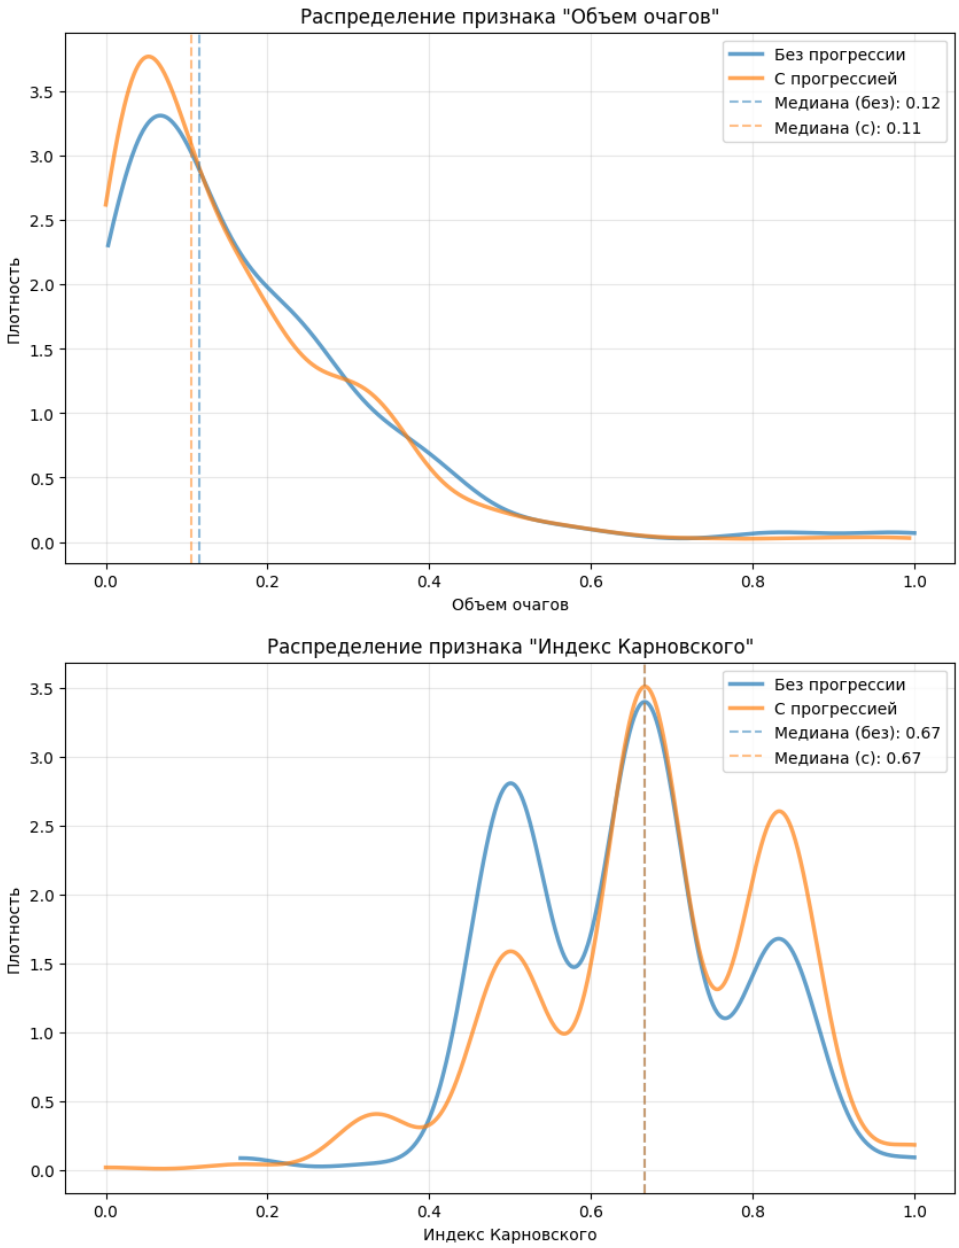

Рис. 6: а и б

Индекс Карновского. Средние значения также почти не отличаются (0.64 против 0.67), перекрытие около 90 %.
По графику плотности индекса Карновского кривые и медианы двух групп практически совпадают (рис. 6 б).
Это указывает на то, что общий функциональный статус пациента не разделяет группы прогрессии и стабильности

Возраст, время метастазирования, время реагирования. Различия между группами малы (разница в среднем <13 %, перекрытие >90 %).
Графики плотностей для этих признаков показывают почти полное наложение распределений между группами (рис. 7), то есть они не являются информативными предикторами прогрессии в одновариантном анализе.

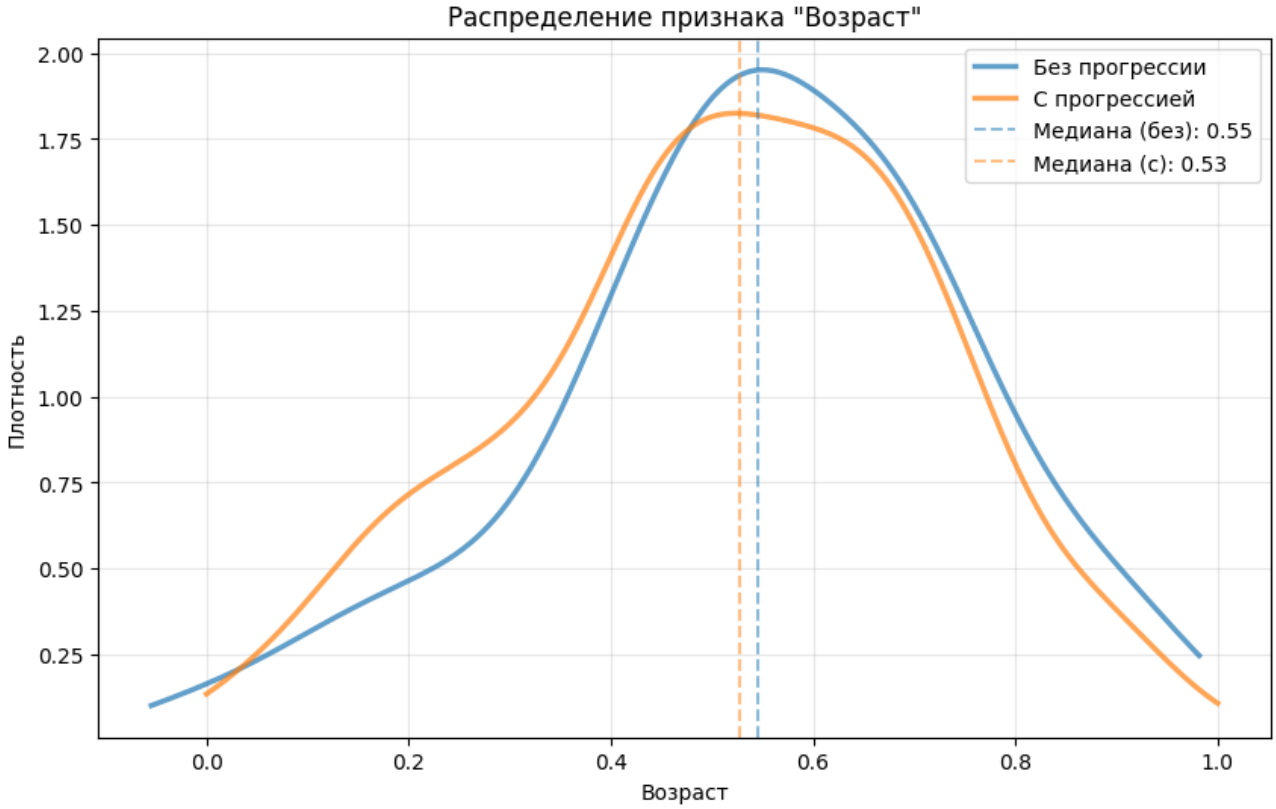

Рис. 7:

Итого по числовым признакам:
«Число РХ процедур» — сильный маркер прогрессии.
«Число очагов» — умеренный маркер.
Остальные признаки визуально и численно почти не различаются.

Результаты анализа категориальных признаков:

ОВГМ: R=0.75 против 0.66, шансы 3.00 против 1.94 — пациенты с ОВГМ чаще имеют прогрессию(рис 8 а).
Операция: R=0.748 против 0.654, шансы 2.97 против 1.89 — операция связана с повышенным риском прогрессии, отражая тяжёлые случаи(рис 8 б).
КРР: R=0.564 против 0.682 — пациенты с КРР прогрессируют реже(рис 8 в).

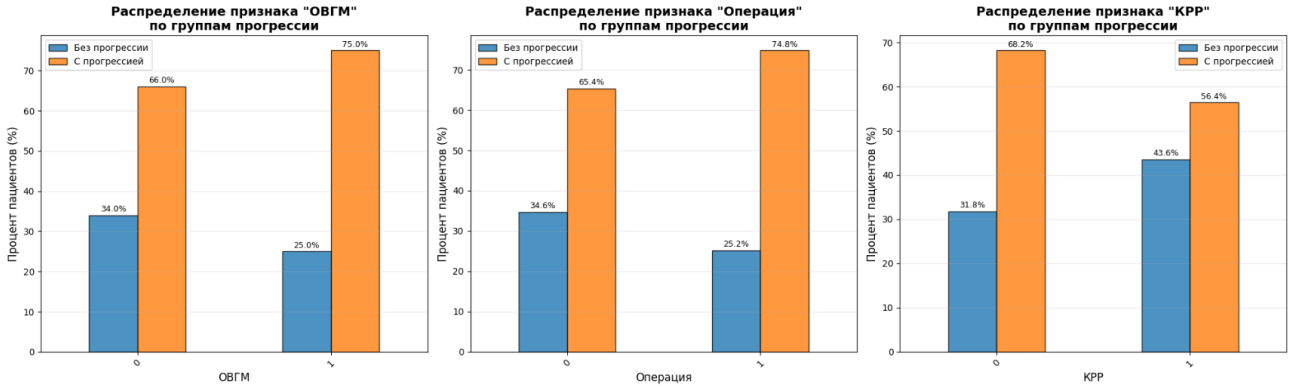

Рис. 8: а б в

Меланома: R=0.721 против 0.662, шансы 2.59 против 1.96 — наличие меланомы связано с большей частотой прогрессии(рис. 9 а).
НМРЛ: 0.655 против 0.680 — различия несущественны(рис. 9 б).

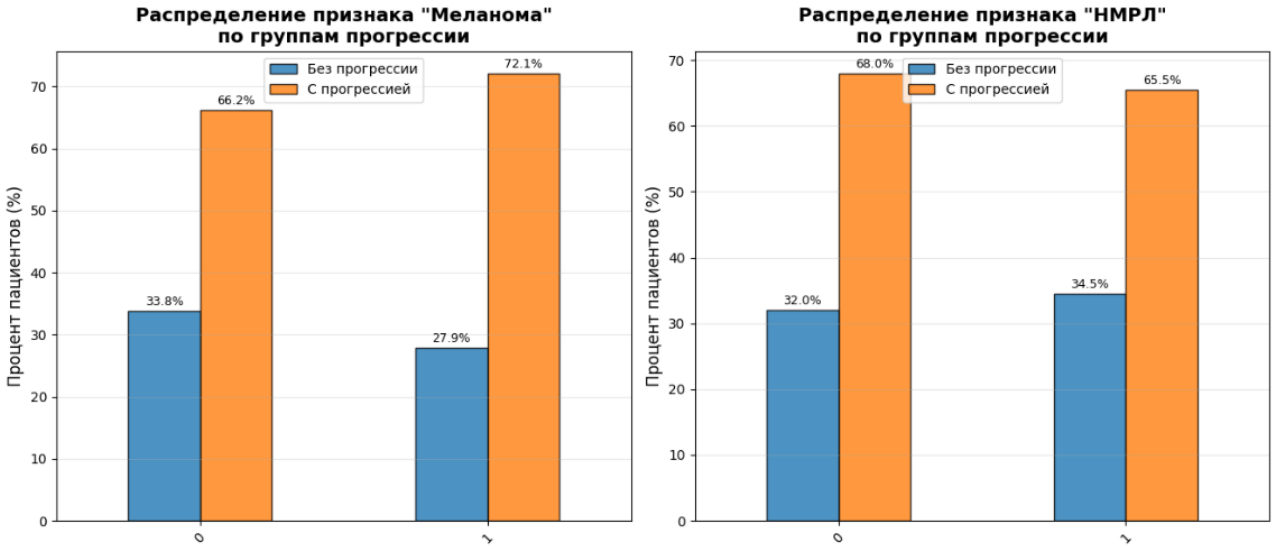

Рис. 9: а и б

Таргетная терапия: R=0.745 против 0.646, шансы 2.92 против 1.82 — пациенты на таргетной терапии чаще находятся в группе прогрессии(рис. 10 а). РМЖ, РП, Химиотерапия: различия минимальны (<3%). На графиках доли прогрессии визуально одинаковы(рис. 10 б).

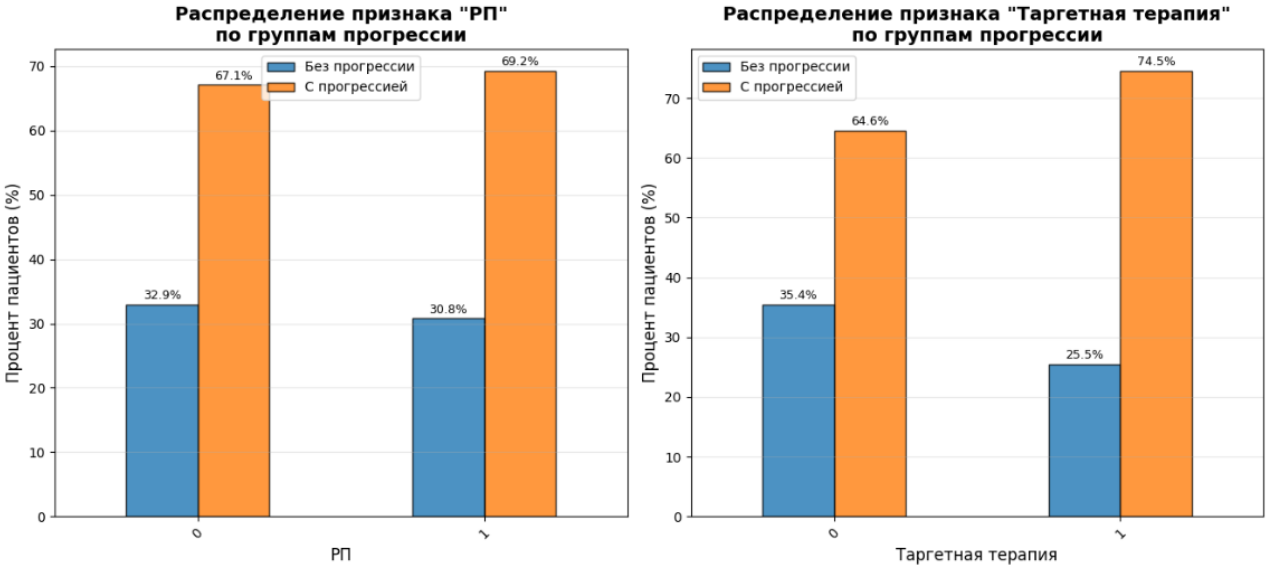

Рис. 10: а и б

Без лечения: 0.588 против 0.676 — пациенты без лечения имеют меньший риск прогрессии, что объясняется стабильным состоянием(рис. 11 а). Мужчина: R(0)=68.6%, R(1)=65.2%, RD=0.034, RR=1.05, OR=1.17 — различия незначительные, графически, распределение симметрично(рис. 11 б).

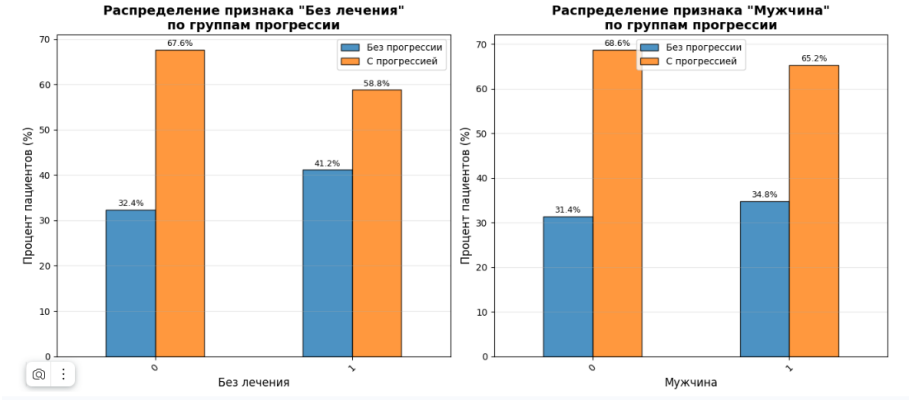

Рис. 11: а и б

6 Экспериментальный протокол сравнения моделей

6.1 Сравнение базовых и ансамблевых моделей

В рамках комплексного экспериментального протокола протестированы 11 алгоритмов машинного обучения для прогнозирования ИП. Кросс-валидация проводилась стратифицированным k-fold ($k = 5$, random_state=42) с метрикой balanced_accuracy.

Таблица 2: Сравнение моделей по balanced accuracy (5-fold CV)

Модель	**Balanced accuracy**
Логистическая регрессия	0.618
Дерево решений	0.636
kNN	0.600
SVM RBF	0.645
LDA	0.600
Бэггинг на kNN	0.636
Случайный лес	0.636
AdaBoost	**0.682**
Стекинг	0.636
Voting Classifier	0.627

Ансамблевые методы (64.0% в среднем) превзошли базовые модели (61.8%), что обусловлено их устойчивостью к переобучению и способностью интегрировать нелинейные зависимости.

6.2 Финальная модель: CatBoost с оптимизацией гиперпараметров

На основе результатов сравнения (табл. 2) разработана итоговая модель на базе CatBoostClassifier с расширенным протоколом оптимизации:

Для количественной оценки дисбаланса классов в обучающей выборке вычислялись веса классов по формуле:

$$w_{\text{positive}} = 1.0, \quad w_{\text{negative}} = \frac{N_{\text{negative}}}{N_{\text{positive}}}$$

где N_{positive} и N_{negative} — количество объектов положительного и отрицательного классов соответственно.

Для поиска оптимальных гиперпараметров использовался RandomizedSearchCV со следующими настройками:

1. Количество итераций: 150
2. Метрика оптимизации: balanced_accuracy
3. Количество фолдов: 5 (стратифицированных)
4. Параллельные вычисления: njobs=-1

После определения оптимальных гиперпараметров проводилась дополнительная калибровка порога классификации. Вместо стандартного порога 0.5 использовалась стратегия Out-of-Fold (OOF) прогнозирования:

1. Для каждого фолда кросс-валидации обучалась модель на *train* части и предсказывались вероятности для *validation* части.
2. Собирались OOF-прогнозы для всей обучающей выборки:

$$\mathbf{p}_{\text{oof}} = \{p_{\text{oof}}^{(1)}, p_{\text{oof}}^{(2)}, \ldots, p_{\text{oof}}^{(N)}\}$$

   где N – размер обучающей выборки, $p_{\text{oof}}^{(i)}$ – вероятность принадлежности к положительному классу для i-го объекта, полученная только на фолде, где этот объект был в валидационной части.

3. Оптимальный порог t^* определялся максимизацией balanced accuracy на диапазоне [0.05, 0.95] с шагом 0.005:

$$t^* = \arg \max_{t \in [0.05,\, 0.95]} \text{BalancedAccuracy}\left(\mathbf{y}_{\text{train}},\, \mathbb{I}(\mathbf{p}_{\text{oof}} \geq t)\right)$$

Итоговая модель обучалась на всем тренировочном наборе данных с лучшими найденными гиперпараметрами. Оценка качества проводилась на независимой тестовой выборке с использованием калиброванного порога tt.

Основной метрикой оценки была выбрана Balanced Accuracy, вычисляемая как среднее арифметическое чувствительности (sensitivity) и специфичности (specificity).

В результате 150 итераций RandomizedSearchCV была определена следующая оптимальная конфигурация CatBoostClassifier:

Гиперпараметр	**Оптимальное значение**
bootstrap_type	Bayesian
depth	7
iterations	1419
learning_rate	0.0044
l2_leaf_reg	16.88
min_data_in_leaf	35
random_strength	3.84
rsm	0.522
bagging_temperature	4.93

Таблица 3:

Лучшая модель, полученная в ходе RandomizedSearchCV, достигла balanced accuracy = 0.7830 ± 0.0072 (среднее значение и стандартное отклонение по 5 фолдам). Данный результат был получен при использовании стандартного порога классификации 0.5.

6.3 Интерпретируемость: SHAP-анализ

SHAP-анализ (TreeExplainer) выявил ключевые факторы риска ИП: число РХ-процедур на ГН (53.0% вклада, mean|SHAP| = 1.22), число очагов (10.4%), возраст (5.8%).

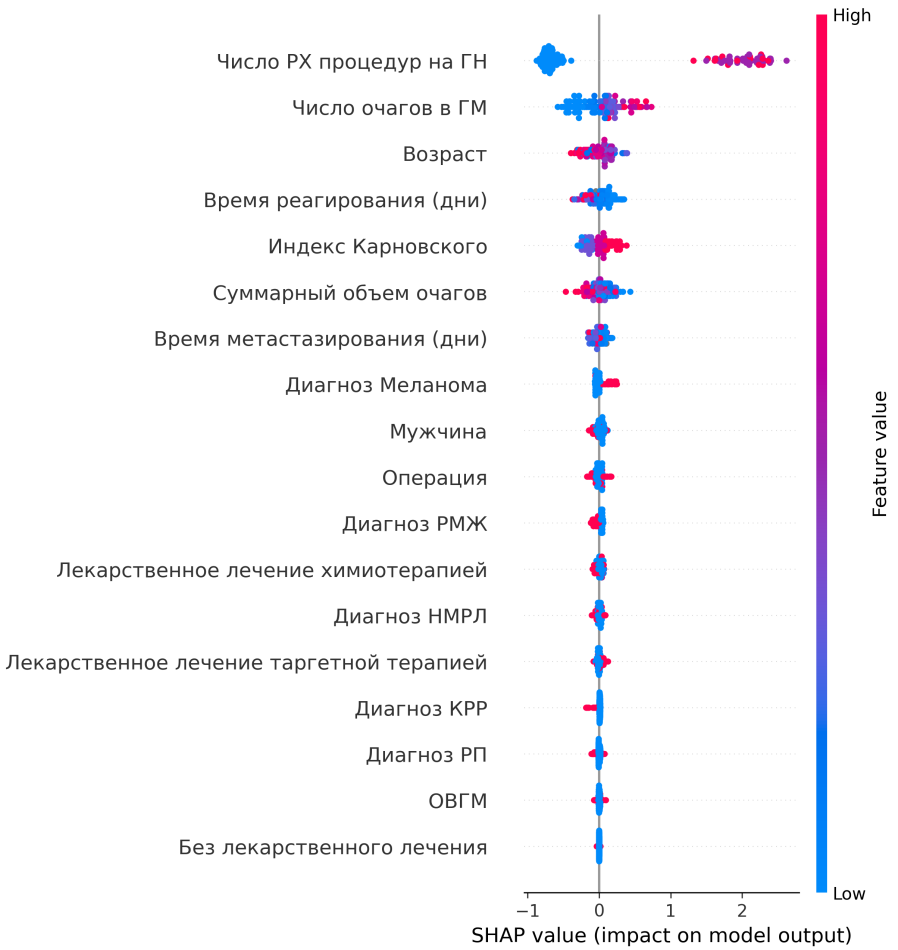
Число РХ процедур на ГН
Число очагов в ГМ
Возраст
Время реагирования (дни)
Индекс Карновского
Суммарный объем очагов
Время метастазирования (дни)
Диагноз Меланома
Мужчина
Операция
Диагноз РМЖ
Лекарственное лечение химиотерапией
Диагноз НМРЛ
Лекарственное лечение таргетной терапией
Диагноз КРР
Диагноз РП
ОВГМ
Без лекарственного лечения
−1
0
1
2
SHAP value (impact on model output)
High
Low
Feature value

Рис. 12:

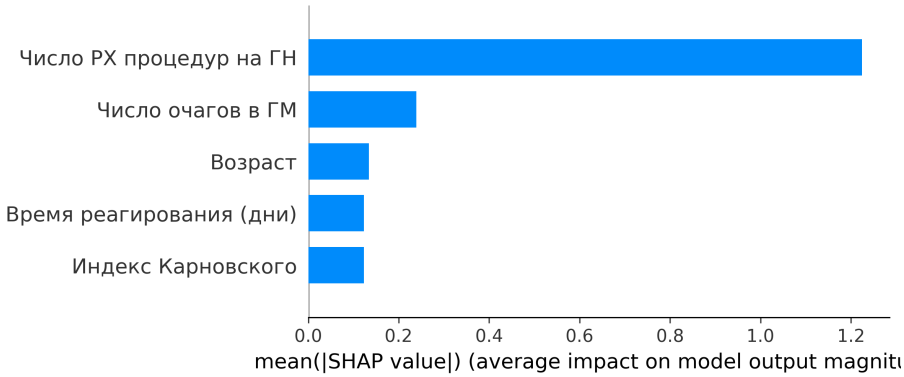
Число РХ процедур на ГН
Число очагов в ГМ
Возраст
Время реагирования (дни)
Индекс Карновского
0.0
0.2
0.4
0.6
0.8
1.0
1.2
mean(|SHAP value|) (average impact on model output magnitu

Рис. 13:

7 Заключение

В ходе исследования была успешно разработана и оптимизирована модель МО для прогнозирования ИП МГМ на основе клинических данных.

7.1 Ключевые результаты

1. Алгоритм CatBoost с подобранными гиперпараметрами продемонстрировал высокую эффективность, достигнув balanced accuracy 0.7839 на независимой тестовой выборке.

2. Оптимизация порога классификации методом OOF-прогнозирования позволила улучшить качество модели, определив оптимальное значение порога 0.525 вместо стандартного 0.5.

3. Полученная конфигурация модели характеризуется умеренной глубиной деревьев (7), низкой скоростью обучения (0.0044) и значительными регуляризационными мерами, что обеспечивает баланс между точностью и устойчивостью к переобучению.

7.2 Клиническая интерпретация ключевых факторов

Число РХ-процедур на ГН доминирует в прогнозе модели. Важно отметить, что у 75% пациентов значение равно 0.0 (первая процедура), а 90% квантиль составляет 0.1 (лишь 10% имели повторные процедуры). Тем не менее, даже одна процедура ГН даёт высокий SHAP-вклад, что клинически трактуется как маркер агрессивного биологического поведения МГМ. Повторные процедуры сигнализируют о радиорезистентности опухоли — способность метастазов выживать после высокодозного облучения.

Число очагов в ГМ занимает второе место. 75% квантиль 0.2 и 90% квантиль 0.4 указывают, что большинство пациентов имеют 1 очаг, но наличие даже одного очага в мозге уже повышает риск ИП. Модель выделяет мультифокальность как индикатор системного метастатического потенциала первичной опухоли. Клинически это означает необходимость поиска отдалённых очагов вне головы и более агрессивную системную терапию.

Возраст демонстрирует нелинейную зависимость с пиком влияния в пожилом возрасте (75% квантиль 0.7). Пациенты старше 65–70 лет имеют сни-

женный иммунный контроль, что способствует прогрессии МГМ несмотря на РХ.

Время реагирования отражает терапевтическую задержку (75% квантиль 0.1). Даже небольшая отсрочка позволяет микроочагам вырасти вне зоны облучения ГН, что объясняет вклад в ИП.

Индекс Карновского выступает защитным фактором: высокие значения (KPS>80, 75% квантиль 0.6) ассоциированы с отрицательным SHAP-вкладом. Пациенты с хорошим функциональным статусом лучше переносят терапию и имеют более благоприятный прогноз.

7.3 Практическая применимость

Разработанная модель может быть интегрирована в системы поддержки врачебных решений для раннего выявления пациентов с высоким риском прогрессирования заболевания, что позволит своевременно назначать профилактические мероприятия и персонализировать лечение.

Благодарности

Авторы хотят поблагодарить преподавателей за интересный материал, полезные семинары и лекции, внимание к каждой команде и готовность всегда помочь разобраться в любом вопросе. Курс позволил по-новому взглянуть на науку и окружающий мир. Отдельно хотим сказать спасибо команде ЦУ за чуткость в течение курса:)

Список литературы

[1] Банов С. М., Голанов А. В., Зайцев А. М., Беляшев А. Х., Ветлована Е. Р., Дургарян А. А. Метастатическое поражение головного мозга, современные стандарты лечения // *Российский медицинский журнал.* — 2017. — №16. — С. 1181–1185.

[2] Важенин Г. А., Банов С. М., Голанов А. В., Рабов П. Н., Далечина А. В. Использование машинного обучения для прогнозирования выживаемости у пациентов с метастатическим поражением головного мозга после

радиохирургического лечения на аппарате Гамма-нож // *Вестник Национального исследовательского ядерного университета "МИФИ"*. — 2018. — Т. 7. — №6. — С. 537–544.

[3] Khalighi S., Reddy K., Midya A., Pandav K. B., Madabhushi A., Abedalthagafi M. Artificial intelligence in neuro-oncology: advances and challenges in brain tumor diagnosis, prognosis, and precision treatment // *npj Precision Oncology*. — 2024. — Vol. 8. — Art. no. 80.

[4] Li J., Dan K., Ai J. Machine learning in the prediction of immunotherapy response and prognosis of melanoma: a systematic review and meta-analysis // *Frontiers in Immunology*. — 2024. — Vol. 15. — Art. no. 1281940.